



CS 2566/CS-64

รายงานความก้าวหน้าโครงการครั้งที่ 1

ระบบตรวจจับข้อความไม่เป็นทางการในเอกสาร

Informal Text Detection System

โดย

643020043-0 นายณัฐนันท์ ทองชุมภู

643021217-8 นายกิตติภพ เพ็ชรโปรี

อาจารย์ที่ปรึกษา : อ.ดร.พงษ์ศธร จันทร์ยอย

รายงานเล่มนี้เป็นส่วนหนึ่งของการศึกษาวิชา SC313762 ระเบียบวิธีวิจัย

ภาคการเรียนที่ 2 ปีการศึกษา 2566

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์

มหาวิทยาลัยขอนแก่น

(เดือน มีนาคม พ.ศ. 2567)



CS 2566/CS-64

รายงานความก้าวหน้าโครงงานครั้งที่ 1

ระบบตรวจจับข้อความไม่เป็นทางการในเอกสาร

Informal Text Detection System

โดย

643020043-0 นายณัฐนันท์ ทองชุมภู

643021217-8 นายกิตติภพ เพ็ชรโปรี

อาจารย์ที่ปรึกษา : ดร.พงษ์ศธร จันทร์ยอย

รายงานเล่มนี้เป็นส่วนหนึ่งของการศึกษาวิชา SC313762 ระเบียบวิธีวิจัย

ภาคการเรียนรู้ที่ 2 ปีการศึกษา 2566

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์

มหาวิทยาลัยขอนแก่น

(เดือน มีนาคม พ.ศ. 2567)

ณัฐนันท์ ทองชุมภู และ กิตติภพ เพ็ชรโปรี. 2567. ระบบตรวจจับข้อความไม่เป็นทางการในเอกสาร.

โครงการวิจัย ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

อาจารย์ที่ปรึกษา: อ.ดร.พงษ์ศธร จันทร์ยอย

บทคัดย่อ

การเขียนงานเอกสารเป็นงานที่อาศัยการใช้คำศัพท์และข้อความที่เป็นทางการเพื่อเพิ่มความน่าเชื่อถือและมีความเป็นสากล ในการตรวจสอบคำไม่เป็นทางการในเอกสารนั้นต้องใช้เวลาและบุคคลที่มีความเชี่ยวชาญในการตรวจสอบ ซึ่งอาจก่อให้เกิดความล่าช้าและใช้ทรัพยากรมนุษย์ในการทำงาน

งานวิจัยนี้ศึกษาการตรวจจับคำไม่เป็นทางการในเอกสารด้วยการฝึกโมเดลภาษาไทยที่ถูกฝึกมาก่อนหน้าคือ WangchanBERTa จากชุดข้อมูลเอกสารวิจัยจากรายวิชาสัมมนาทางวิทยาการคอมพิวเตอร์จำนวน 100 ประโยคและชุดข้อมูลคำไม่สุภาพจำนวน 500 ประโยค โดยจะทำการเก็บค่าความแม่นยำจากการฝึกโมเดลในแต่ละรอบเพื่อทำการคัดเลือกโมเดลที่มีค่าความแม่นยำที่ดีที่สุดสำหรับการทำนายคำไม่เป็นทางการจากข้อความ

จากการทดลองพบว่าโมเดลที่ได้ให้ค่า F1-Score อยู่ที่ 70.96% ทางผู้วิจัยคาดว่าโมเดลจะมีประสิทธิภาพดีมากขึ้นหากมีจำนวนข้อมูลข้อความไม่เป็นทางการในเอกสารสำหรับการฝึกจำนวนมากและการระบุคำไม่เป็นทางการในข้อความไม่เป็นทางการในเอกสารควรถูกระบุโดยผู้เชี่ยวชาญ

คำสำคัญ: การเรียนรู้ของเครื่อง, โมเดลภาษา, การประมวลผลภาษาธรรมชาติ, การตรวจจับข้อความไม่เป็นทางการ

Natthanan Thongchomphu and Kittipop Phetporee. 2024. **Informal Text Detection System.**

Bachelor of Science Program Research Project in Computer Science, College of Computing, Khon Kaen University.

Thesis Advisors: Pongsathon Janyoi, Ph.D.

ABSTRACT

Writing documents involves using formal vocabulary and text to enhance credibility and internationality. Checking for informal words in documents requires time and personnel with expertise to review, which may lead to delays and human resource consumption.

This research investigates the detection of informal words in documents using the pre-trained language model WangchanBERTa trained on research paper datasets from seminar in computer science class. The dataset consists of 100 sentences and a dataset of vulgar words comprising 500 sentences. The model's accuracy will be evaluated in each round of training to select the best-performing model for predicting informal words from text.

From the experiments, the model achieved an F1-Score of 70.96%. The researchers anticipate that the model's performance will improve significantly with a larger dataset of informal words in documents for extensive training and accurate identification of informal words in the document should be identified by experts.

Keywords: Machine Learning, Language Model, Natural Language Processing, Informal Text Detection

กิตติกรรมประกาศ

ในการดำเนินโครงการครั้งนี้ ผู้จัดทำโครงการได้รับความอนุเคราะห์ และความช่วยเหลือจากบุคคลหลายท่านด้วยกัน จึงขอขอบคุณไว้ ณ โอกาสนี้

ขอขอบพระคุณอาจารย์ทุกท่านที่ให้ความรู้และอบรมสั่งสอน

ขอขอบพระคุณอาจารย์ ดร.พงษ์ศธร จันทร์ยอย ที่เป็นที่ปรึกษาโครงการและได้ให้คำชี้แนะแนวทางในการคิดวิเคราะห์ และการพัฒนาระบบของโครงการนี้

ขอขอบคุณ คุณพ่อ คุณแม่ ที่เป็นกำลังใจในการเรียนและการทำโครงการมาโดยตลอด

ขอบคุณเพื่อน ๆ ที่ให้การสนับสนุนเอกสารวิจัยเพื่อใช้เป็นข้อมูลในการทำโครงการนี้

ผู้จัดทำ

ณัฐนันท์ ทองชุมภู

กิตติภพ เพ็ชรโปรี

สารบัญ

	หน้า
บทคัดย่อภาษาไทย	ก
บทคัดย่อภาษาอังกฤษ	ข
กิตติกรรมประกาศ	ค
สารบัญ	ง
สารบัญตาราง	จ
สารบัญภาพ	ฉ
บทที่ 1 บทนำ	1
1. ความเป็นมาและความสำคัญของปัญหา	1
2. วัตถุประสงค์ของโครงการ	1
3. เป้าหมายและขอบเขต	1
4. ประโยชน์ที่คาดว่าจะได้รับ	1
บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง	2
1. ทฤษฎีที่เกี่ยวข้อง	2
2. งานวิจัยที่เกี่ยวข้อง	5
บทที่ 3 วิธีการดำเนินงาน	8
1. วิธีการดำเนินงานวิจัย	8
2. แผนและระยะเวลาดำเนินงาน	11
3. เครื่องมือที่ใช้ในการดำเนินงาน	12
บทที่ 4 ผลการดำเนินงาน	13
1. การเก็บรวบรวมและเตรียมข้อมูลที่ใช้ในการศึกษา	13
2. การทดสอบผลการดำเนินงาน	15
บทที่ 5 บทสรุป	16
1. สรุปผลการดำเนินโครงการ	16
2. ปัญหาอุปสรรค และ แนวทางแก้ไข	16
3. ข้อเสนอแนะ ในการพัฒนาต่อไป	16
บรรณานุกรม	17
ประวัติผู้เขียน	19

สารบัญตาราง

	หน้า
ตารางที่ 1 ตารางแสดงตัวอย่างรายละเอียดของ Data Frame สำหรับการฝึกและทดสอบโมเดล	9
ตารางที่ 2 แผนและระยะเวลาดำเนินงาน	11

สารบัญภาพ

	หน้า
ภาพที่ 1 ตัวอย่างคำไม่เป็นทางการและคำเป็นทางการ	2
ภาพที่ 2 ตัวอย่างปัญหาความกำกวมในการตัดคำ	3
ภาพที่ 3 ตัวอย่างการแปลงคำเป็นเวกเตอร์ของการฝังคำ	4
ภาพที่ 4 ตัวอย่างการติดฉลากลำดับ	4
ภาพที่ 5 ภาพแสดงขั้นตอนการปฏิบัติการทดลอง	9
ภาพที่ 6 ตัวอย่างชุดข้อมูลคำไม่เป็นทางการในเอกสารจาก Google Sheet	13
ภาพที่ 7 ตัวอย่างชุดข้อมูลไม่สุภาพจาก Google Sheet	14
ภาพที่ 8 แผนภูมิแท่งแสดงจำนวนความถี่ของประเภทของคำระหว่าง O และ INF	14
ภาพที่ 9 ผลการวัดประสิทธิภาพของโมเดลจากชุดข้อมูลทดสอบ	15

บทที่ 1

บทนำ

1. ความเป็นมาและความสำคัญของปัญหา

การเขียนงานเอกสารเป็นงานที่อาศัยการใช้คำศัพท์และข้อความที่เป็นทางการ ไม่ว่าจะเป็นการเขียนงานวิจัย การทำโครงการ หรือแม้กระทั่งเอกสารทั่วไปนั้นต้องอาศัยการใช้คำที่เป็นทางการเพื่อเพิ่มความน่าเชื่อถือและมีความเป็นสากล ในการตรวจสอบคำไม่เป็นทางการในเอกสารนั้นต้องใช้เวลาและบุคคลที่มีความเชี่ยวชาญในการตรวจสอบ ซึ่งก่อให้เกิดความล่าช้าและใช้ทรัพยากรมนุษย์ในการทำงาน

การประมวลผลภาษาธรรมชาติ (Natural Language Processing) เป็นสิ่งสำคัญในการวิเคราะห์ข้อความและคำพูดได้อย่างมีประสิทธิภาพด้วยการเรียนรู้ของเครื่อง (Machine Learning) ที่ช่วยให้คอมพิวเตอร์สามารถตีความ จัดการ และทำความเข้าใจภาษามนุษย์ได้ ซึ่งปัจจุบันโมเดลภาษาที่ถูกฝึกก่อนหน้านี้ (Pre-trained Language Model) ได้ถูกพัฒนาขึ้นจากการเรียนรู้ของเครื่องโดยได้รับการฝึกจากชุดข้อมูลจำนวนมากและได้ถูกนำไปประยุกต์ใช้ในงานต่าง ๆ เช่น งานแปลภาษา แชทบอท การทำนายข้อความถัดไป การจำแนกหมวดหมู่ของบทความหรือแม้กระทั่งการจัดการกับข้อความในเอกสาร

จากปัญหาดังกล่าวได้จุดประกายให้ทางผู้วิจัยได้เล็งเห็นถึงปัญหาดังกล่าว โดยทางผู้วิจัยได้ทำการใช้ความสามารถของโมเดลภาษาที่ถูกฝึกก่อนหน้านี้และการประมวลผลภาษาธรรมชาติในการตรวจจับข้อความไม่เป็นทางการในเอกสารภาษาไทย เพื่อลดระยะเวลาในการตรวจสอบและการเกิดค่าใช้จ่ายจากการใช้ทรัพยากรมนุษย์ในการทำงาน

2. วัตถุประสงค์ของโครงการ

เพื่อสร้างระบบตรวจจับข้อความไม่เป็นทางการในเอกสาร

3. เป้าหมายและขอบเขต

ระบบสามารถตรวจจับข้อความไม่เป็นทางการที่เป็นภาษาไทย

4. ประโยชน์ที่คาดว่าจะได้รับ

ได้ระบบตรวจจับข้อความไม่เป็นทางการในเอกสาร

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

1. ทฤษฎีที่เกี่ยวข้อง

ในการดำเนินงานวิจัยระบบตรวจจับข้อความไม่เป็นทางการในเอกสารนี้ ทางด้านคณะผู้วิจัยได้ทำการรวบรวมแนวคิดทฤษฎีต่าง ๆ โดยมีเนื้อหาและรายละเอียดดังต่อไปนี้

1.1. การประมวลผลภาษาธรรมชาติ

การประมวลผลภาษาธรรมชาติ หมายถึงกระบวนการที่จะคำนวณและวิเคราะห์ภาษาธรรมชาติ โดยที่การประมวลผลภาษาธรรมชาติมีบทบาทสำคัญในการพัฒนาระบบ การประมวลผลภาษาธรรมชาติสามารถอำนวยความสะดวกในการประมวลผลข้อความและข้อมูลขนาดใหญ่ เช่น การดึงข้อมูล การแก้ไขข้อผิดพลาด ถึงแม้ว่าการประมวลผลภาษาธรรมชาติจะใช้เวลาในการประมวลผลและตัดสินใจนานและมีค่าใช้จ่ายที่สูง แต่การนำการประมวลผลภาษาธรรมชาติจะเพิ่มประสิทธิภาพของระบบได้ดียิ่งขึ้น นอกจากนี้การประมวลผลภาษาธรรมชาติยังช่วยให้ใช้งานวิเคราะห์และดึงข้อมูลจากแหล่งต่าง ๆ หลากหลายที่ได้ เช่น การชุดข้อมูล การรู้และจดจำเสียง การวิเคราะห์ความรู้สึก และการประมวลผลข้อความ

1.2. คำไม่เป็นทางการในภาษาไทย

คำไม่เป็นทางการในภาษาไทย เป็นภาษาที่ไม่เคร่งครัด เพื่อใช้ในการสื่อสารทั่วไปในชีวิตประจำวัน หรือในโอกาสที่ไม่เป็นทางการ ใช้ในการสนทนาระหว่างบุคคล กลุ่มเล็ก ๆ หรือในสถานที่ทั่ว ๆ ไปที่ไม่เป็นการส่วนตัว เช่น การเขียนจดหมายระหว่างเพื่อน การคุยกันระหว่างบุคคลตามที่สาธารณะ โดยที่ภาษาอาจเป็นถ้อยคำที่ใช้กันในเฉพาะกลุ่มหรือเป็นภาษาพูดที่สุภาพ และการสนทนาไม่เกิน 5 คน

คำไม่เป็นทางการ	คำเป็นทางการ
พ่อ, แม่	บิดา, มารดา
ตาย	เสียชีวิต, ถึงแก่กรรม
โรงหนัง	โรงภาพยนตร์
प्ั้ว, เมีย	สามี, ภรรยา

ภาพที่ 1 ตัวอย่างคำไม่เป็นทางการและคำเป็นทางการ

1.3. การตัดคำภาษาไทย

การตัดคำภาษาไทยเป็นการประมวลผลภาษาธรรมชาติ โดยทำการแยกคำเพื่อนำคำที่แยกแล้วไปใช้ฝึกโมเดลต่อ ๆ ไป เช่น การตรวจสอบตัวสะกดภาษาไทย การวิเคราะห์ไวยากรณ์ การแปลภาษาด้วยเครื่อง เป็นต้น เนื่องจากภาษาไทยมีการเขียนประกอบไปด้วยสระและวรรณยุกต์ประกอบอยู่ อีกทั้งยังเขียนติดกันทั้งประโยค และพยางค์บางตัวสามารถเป็นได้ทั้งตัวสะกดหรือสระ จึงทำให้ภาษาไทยมีความแตกต่างจากภาษาอื่น ๆ และอาจทำให้เกิดความกำกวมในการตัดคำ

จันนอนตากลม


จัน | นอน | ตาก | ลม

จัน | นอน | ตา | กลม

ภาพที่ 2 ตัวอย่างปัญหาความกำกวมในการตัดคำ

1.4. การฝังคำ

การฝังคำ (Word Embedding) หรือการแปลงคำเป็นตัวเลข เป็นการสกัดคุณลักษณะของคำโดยผลลัพธ์ที่ได้ อยู่ในรูปแบบเวกเตอร์ โดยที่คำหนึ่งคำหรือ Token จะสามารถแทนค่าได้ด้วยตัวเลขชุดนี้ ซึ่งมีหลายวิธีการแปลงคำ เช่น Bag of Words (BOW), Count Vectorizer, TF-IDF, Word2vec และ GloVe



ภาพที่ 3 ตัวอย่างการแปลงคำเป็นเวกเตอร์ของการฝังคำ

1.5. การติดฉลากลำดับ

การติดฉลากลำดับ (Sequence Labeling) เป็นการกำหนดป้ายกำกับหรือแท็กให้กับชุดข้อมูลของการประมวลผลภาษาธรรมชาติ กล่าวคือทำการระบุประเภทให้คำ เมื่อเอนทิตีถูกกำหนดแท็กให้ เรียกว่า Named entity Recognition (NER) และเมื่อใส่แท็กให้กับคำพูด จะเรียกว่า Part-of-Speech (PoS)

Named Entity Recognition

ลุง	ตุ๋	ตอบว่า	ผู้สื่อข่าว	ที่	ตึกไทยคู่ฟ้า	เมื่อ	เช้า
↓	↓	↓	↓	↓	↓	↓	↓
B-PER	I-PER	O	O	O	B-PLACE	B-TIME	I-TIME

Vulgar Tagging

คนนี้	นิสัย	เหี้ย	มาก
↓	↓	↓	↓
O	O	B-VUL	O

ภาพที่ 4 ตัวอย่างการติดฉลากลำดับ

1.6. Transformers

Transformers หรือตัวแปลง เป็นโครงข่ายประสาทเทียมชนิดหนึ่งที่แปลงหรือเปลี่ยนลำดับของอินพุตและเอาต์พุต โดยการฝึกให้เรียนรู้ทั้งบริบทและลำดับความสัมพันธ์ตามลำดับ เช่น “สีของท้องฟ้าคืออะไร” โดยที่โมเดลนี้จะแปลงและระบุความเกี่ยวข้องและความสัมพันธ์ระหว่างคำว่า สี ท้องฟ้า และสีฟ้า ซึ่งทำได้ผลลัพธ์ว่า “ท้องฟ้าเป็นสีฟ้า” ด้วยกลไกให้ความสนใจ (Attention Mechanism) ซึ่งเป็นกลไกที่ให้โมเดลสนใจเพียงคำที่มีความสำคัญกับบริบท

1.7. โมเดลภาษา

โมเดลภาษา (Language Model) เป็นปัญญาประดิษฐ์ที่มีความถนัดและความสามารถในการเข้าใจภาษาของมนุษย์ จัดจำลักษณะภาษาของมนุษย์ และสามารถทำนายค่าที่หายไปโดยอ้างอิงจากคำอื่น ๆ ในประโยค โดยที่โมเดลสามารถนำไปประยุกต์ใช้ได้หลายรูปแบบ เช่น การตอบคำถาม การแปลภาษา การแต่งเติมเนื้อหา หรือการสรุปข้อความ โดยที่โมเดลที่ได้รับการพัฒนาขึ้น จะเรียกว่า Pre-trained ซึ่งเป็นการให้โมเดลเรียนรู้จากแหล่งข้อมูลในแหล่งข้อมูลสาธารณะในปริมาณมาก ๆ เพื่อนำมาทำนายค่าที่หายไป

2. งานวิจัยที่เกี่ยวข้อง

Lalita Lowphansirikul, Charin Polpanumas, Nawat Jantrakulchai และ Sarana Nutanong (2021) กล่าวว่าโมเดลภาษา Transformer โดยเฉพาะ BERT ได้รับความนิยมและมีประสิทธิภาพที่ยอดเยี่ยมในงานด้านการจำแนกข้อความ เฉพาะอย่างยิ่งในภาษาที่มีทรัพยากรอย่างจำกัด เช่นภาษาไทย การใช้ BERT ในภาษาไทยมีข้อจำกัดในการฝึกเพราะข้อมูลที่น้อยและการปรับแต่งโมเดลภาษานั้นมีความซับซ้อน เพื่อที่จะลบข้อจำกัดดังกล่าว การนำ RoBERTa ที่เป็น Pre-trained โมเดล โดยจะนำข้อมูลที่รวบรวมจากแหล่งต่าง ๆ เช่น โดเมนโซเชียลมีเดีย บทความข่าว และข้อมูลอื่น ๆ ที่เปิดเผยต่อสาธารณะมาใช้กับโมเดลนี้ และกฎในการประมวลผลข้อความมาใช้เพื่อจัดการกับภาษาไทยที่มีความเฉพาะเจาะจง จากนั้นได้ทดลองกับโทเค็นระดับคำ ระดับพยางค์ และระดับประโยค ผลการทดสอบพบว่าโมเดล wangchanBERTa-base-att-spm-uncased ที่ถูกฝึกด้วยชุดข้อมูลขนาดใหญ่ 78.5 GB มีประสิทธิภาพที่ดีกว่าโมเดลพื้นฐานอย่าง NBSVM, CRF, และ ULMFit และโมเดลหลายภาษาอื่น ๆ เช่น XLMR และ mbERT ในการจำแนกลำดับและงานจำแนกโทเค็นในงานนั้นจะอธิบายประกอบด้วยบริบทภาษาโดยชาวไทย

Xinyi Li, Ying Qian และ Liang Dou (2021) กล่าวว่าพัฒนาของการประมวลผลภาษาธรรมชาติ ช่วยให้การจำแนกชื่อเฉพาะ (Named Entity Recognition: NER) มีความแม่นยำมากขึ้น อย่างไรก็ตามโมเดลในปัจจุบันในงาน NER ก็ยังพบปัญหาว່ามันไม่สามารถรับรู้ชื่อเฉพาะหรือประเภทของคำที่หลากหลายและผลของการทำ NER ยังไม่ตรงตามที่ควรจะเป็น ในงานวิจัยนี้ได้ใช้ Bidirectional Encoder Representations from Transformers (BERT) ร่วมกับ Bidirectional Long Short-Term Memory (BiLSTM) และฟิลด์สุ่มแบบมีเงื่อนไข (Conditional Random Field: CRF) เพื่อแก้ปัญหาดังกล่าว โดยขั้นตอนการฝึกฝนโมเดลคือนำโมเดล BERT ที่ถูกฝึกก่อนหน้านี้ (Pre-trained) ไปฝึกเพิ่มเติม (Fine-Tuning) หลังจากนั้นจะได้เวกเตอร์ที่แสดงถึงบริบทของข้อความ (Context Vector) แล้วจึงนำไปใช้เป็นข้อมูลที่ป้อนให้กับ BiLSTM และ CRF จากนั้นได้โมเดลที่ฝึกแล้วดำเนินการทดลองกับคลังข้อมูล Microsoft Research

Asia (MSRA) และ Person's Daily จากการทดสอบสรุปได้ว่าการใช้ BERT, BiLSTM และ CRF ร่วมกันมีประสิทธิภาพสูงสุดถึง 94.51% เมื่อเทียบกับ Model อื่น ๆ ซึ่งบ่งบอกถึงประสิทธิภาพของ BERT ในการแก้ปัญหา NER

Bihui Yu, Chen Deng และ Liping Bu (2022) ต้องการที่จะจำแนกข้อความนโยบายภาษาจีนด้วยโมเดล BERT ที่ถูกฝึกโดยใช้ชุดข้อมูล Microsoft Research Paraphrase Corpus (MRPC) ให้สามารถจัดประเภทของข้อความนโยบายที่นำมาจากหน่วยงานของรัฐบาล โดยคุณลักษณะของข้อความนโยบายจะมี ข้อความที่สั้น กระชับ การที่ทำให้ข้อความเป็นมาตรฐานเดียวกันโดยที่โครงสร้างของประโยคจะประกอบไปด้วยประโยคหลักและประโยครอง อีกทั้งยังมีเนื้อหาของแต่ละบทความที่ครอบคลุมไม่เท่ากัน และยังมีในส่วนของความหลากหลายที่ยังคงทำให้จำแนกได้ยากขึ้น จึงได้ทำการทดลองโดยนำโมเดล Convolutional Neural Network (CNN), BiLSTM, และ CNN-BiLSTM ที่เป็นการรวมระหว่าง CNN และ BiLSTM มาใช้งานร่วมกัน เมื่อนำมาเปรียบเทียบกับโมเดล BERT และผลลัพธ์ออกมาได้ว่า BERT มีประสิทธิภาพดีที่สุดถึง 93.25%

Sakib Al Hasan, Md Gulzar Hussain, Joy Protim และคณะ (2022) ได้พบกับปัญหาเกี่ยวกับการทำเหมืองข้อความว่าข้อความทั่ว ๆ ไปบนโลกนั้นเป็นข้อมูลที่ไม่ได้จัดเรียงหรือยังไม่ได้ทำการจัดเตรียมให้เรียบร้อย คณะผู้วิจัยได้สังเกตเห็นปัญหาดังกล่าวและได้ทดสอบความแม่นยำในการจำแนกข้อความในบทความแบบหลายประเภทโดยการใช้ Support Vector Machines (SVM) และใช้ Count Vectorizer และ Term Frequency - Inverse Document Frequency (TF-IDF) เพื่อแปลงข้อมูลให้อยู่ในรูปแบบเวกเตอร์ จากชุดข้อมูล Reuters ผลปรากฏว่า SVM ที่ใช้เป็น Linear Kernel มีความแม่นยำที่ 94.10% ซึ่งมีความแม่นยำมากกว่า SVM ที่ใช้เป็น Polynomial Kernel ถึง 0.82% ซึ่งสรุปได้ว่า SVM ที่ใช้เป็น Linear Kernel มีประสิทธิภาพดีที่สุด

Bo Zhang (2022) กล่าวว่าวิธีการจัดเรียงข้อความด้วยตนเองนั้นทำได้ยากเพราะปัจจุบันมีข้อมูลจำนวนมาก และกล่าวเพิ่มอีกว่ามีเทคโนโลยีการจัดหมวดหมู่ข้อความซึ่งเป็นอีกแขนงหนึ่งในเทคโนโลยีการจัดเหมืองข้อมูล สามารถจัดหมวดหมู่ข้อความจำนวนมากได้อย่างมีประสิทธิภาพ จุดประสงค์ของผู้วิจัยคือต้องการที่จะศึกษาอัลกอริทึมที่ใช้จำแนกข้อความข่าวด้วยการเรียนรู้ของเครื่อง บทความนี้จะสามารถช่วยแก้ปัญหาวิธีการทางการเรียนรู้ของเครื่องแบบเดิม ๆ ที่ต้องใช้เวลาและความพยายามในการสกัดคุณลักษณะของข้อมูลต่าง ๆ ด้วยตนเอง และในบทความนี้ได้ออกแบบโมเดลมา 2 ตัวคือโครงข่ายประสาทเทียมที่ใช้สำหรับสกัดคุณลักษณะ และโครงข่ายประสาทเทียมที่ใช้จัดจำแนกของข้อความคือโมเดล Long-Short Term Memory (LSTM) หลังจากได้ทดสอบตัวอื่น ๆ ประกอบด้วย Latent Dirichlet Allocation (LDA), SVM และ LDA-ID3 มีผลลัพธ์ดังนี้ โมเดล LDA ได้ผลลัพธ์ที่ดีกว่าโมเดล SVM ถึง 20% และอย่างที่สองคือ Iterative Dichotomiser 3 (ID3) ก็ได้ปรับปรุงข้อเสียบางประการของ โมเดล LDA เช่นกัน แต่ถึงอย่างไรก็ตามก็ยังพบข้อบกพร่องคือเทคโนโลยีการจัดหมวดหมู่ข้อความที่ศึกษาในประเทศของผู้วิจัยยังห่างไกลจากการนำไปใช้เชิงพาณิชย์และใช้ในวงกว้าง

Li Jia, Tao Jiang, Jia Hao Meng และ TingTing Zhang (2020) ได้กล่าวว่าข้อมูลบนอินเทอร์เน็ตมีอัตราการเติบโตเร็วเนื่องจากมีจำนวนคนที่ใช้อินเทอร์เน็ตจำนวนมาก จึงทำให้มีข้อมูลจำนวนมากไม่ได้ถูกจัดหมวดหมู่และภาษาที่เบตเป็นส่วนสำคัญของภาษาจีนซึ่งมีประวัติที่ยาวนาน ทางคณะผู้วิจัยจึงอยากที่จะดำรงรักษาภาษาอันเฝ้าไว้ จึงได้ทำการจำแนกประเภทข้อความในภาษาที่เบตและสร้างคลังข้อมูลภาษาที่เบตเพื่อช่วยให้ผู้คนค้นหาหรือรับข้อมูลได้อย่างรวดเร็ว

ด้วยการนำโมเดล BiLSTM มาใช้ในการจำแนกข้อความโดยการนำวิธีการคัดกรองคุณลักษณะของข้อมูล 2 วิธีมาใช้ร่วมกัน Word2Vec และ TF-IDF ซึ่งผลปรากฏว่า BiLSTM มีประสิทธิภาพถึง 89.09% ซึ่งมากกว่า Recurrent Neural Network (RNN) และ LSTM แต่ก็มีข้อเสียคือข้อมูลจำแนกภาษาที่เบตมีจำนวนน้อย ทำให้โมเดลนี้ไม่เหมาะที่จะนำมาใช้งาน

บทที่ 3

วิธีการดำเนินงาน

1. วิธีการดำเนินงานวิจัย

วิธีการดำเนินงานเพื่อพัฒนาระบบตรวจจับข้อความไม่เป็นทางการ ทางผู้จัดทำโครงการได้ดำเนินการตามขั้นตอนดังนี้

1.1. กำหนดหัวข้อโครงการ

เลือกปัญหาที่น่าสนใจและกำหนดหัวข้อโครงการโดยคำนึงถึงประโยชน์และผลกระทบที่ต่อสังคม

1.2. กำหนดเป้าหมายและขอบเขตของโครงการ

โมเดลสามารถทำนายค่าไม่เป็นทางการในเอกสารที่เป็นภาษาไทยได้เท่านั้น

1.3. ศึกษาค้นคว้าเอกสารวิจัยและทฤษฎีที่เกี่ยวข้อง

ผู้วิจัยได้ศึกษาค้นคว้าเอกสารวิจัยและทฤษฎีที่เกี่ยวข้องเพื่อหาวิธีการที่จะสามารถสร้างระบบตรวจจับข้อความไม่เป็นทางการในเอกสารได้ ตั้งแต่ขั้นตอนการเตรียมข้อมูล การสำรวจข้อมูล การฝึกโมเดลภาษาไทยที่ถูกฝึกมาก่อนหน้า และการวัดประสิทธิภาพของโมเดล

1.4. เก็บรวบรวมข้อมูลเอกสารวิจัยที่มีค่าไม่เป็นทางการและที่ถูกแก้ไขให้เป็นทางการ

ผู้วิจัยได้ทำการเก็บรวบรวมข้อมูลไว้ที่ Google Sheet เพื่อจัดเตรียมข้อมูลสำหรับกระบวนการฝึกโมเดลโดยได้ทำการรวบรวมข้อมูลจากแหล่งต่าง ๆ ไว้ดังนี้

1. เอกสารวิจัยจากรายวิชาสัมมนาทางวิทยาการคอมพิวเตอร์ จำนวน ... ประโยค

2. ชุดข้อมูลคำไม่สุภาพ จำนวน 500 ประโยค ประกอบด้วย

2.1. ชุดข้อมูล Wongnai Reviews จำนวน 52 ประโยค

2.2. ชุดข้อมูล Thai Toxicity Tweet จำนวน 397 ประโยค

2.3. ประโยคจากทางผู้วิจัย จำนวน 1 ประโยค

2.4. ความคิดเห็นจากโพสต์ใน X (Twitter) จำนวน 50 ประโยค

1.5. ปฏิบัติการทดลอง

ผู้วิจัยได้ใช้ Google Colab ในการพัฒนาและวัดประสิทธิภาพของโมเดล โดยมีขั้นตอนดังนี้



ภาพที่ 5 ภาพแสดงขั้นตอนการปฏิบัติการทดลอง

จากภาพที่ 1 แสดงขั้นตอนการปฏิบัติการทดลองได้ดังนี้

1.5.1. นำเข้าข้อมูล

นำเข้าข้อมูลจาก Google Sheet ลงใน Google Colab

1.5.2. การเตรียมข้อมูล

ทำการแปลงข้อมูลที่นำเข้าจาก Google Sheet ให้อยู่ในรูปแบบ Data Frame ด้วย Library Pandas สำหรับการฝึกและทดสอบโมเดลโดยมีรายละเอียดดังนี้

ตารางที่ 1 ตารางแสดงตัวอย่างรายละเอียดของ Data Frame สำหรับการฝึกและทดสอบโมเดล

sentence_id	words	labels
0	ฉัน	O
0	กิน	INF
0	อาหาร	O
1	หลวงพ่อ	O
1	รับประทาน	INF
1	อาหาร	INF
...	...	...

จากตารางที่ 1 แสดงตัวอย่างประเภทของคำในประโยค 2 ประโยคได้แก่ “ฉัน<informal>กิน</informal>อาหาร” และ “หลวงพ่อ<informal>รับประทานอาหาร</informal>” ซึ่งได้ถูกตัดคำและแปลงเป็น Data Frame ที่มีทั้งหมด 3 คอลัมน์ได้แก่

1. คอลัมน์ sentence_id ใช้สำหรับเก็บไอดีของประโยคเพื่อให้ข้อมูลว่าคำต่าง ๆ ในคอลัมน์ words มาจากประโยคใด

2. คอลัมน์ words ใช้สำหรับเก็บคำ

3. คอลัมน์ labels ใช้สำหรับเก็บประเภทของคำซึ่งมีทั้งหมด 2 ประเภทคือ O และ INF โดยมีรายละเอียดดังนี้

O แทนคำทั่วไปซึ่งได้มาจากคำที่อยู่ภายนอกแท็ก informal

INF แทนคำไม่เป็นทางการซึ่งได้มาจากคำที่อยู่ภายในแท็ก informal

1.5.3. แบ่งข้อมูลสำหรับการฝึกและทดสอบโมเดล

ทำการแบ่งข้อมูลสำหรับการฝึกและทดสอบโมเดลเป็นอัตราส่วน 10:7 ตามคอลัมน์ sentence_id จากตารางที่ 2

1.5.4. ฝึกโมเดล

นำข้อมูลสำหรับการฝึกไปฝึกโมเดลภาษาไทยคือ WangchanBERTa โดยทำการนำเข้าโมเดลด้วยไลบรารี Simple Transformers

1.5.5. ประเมินประสิทธิภาพของโมเดล

ทำการประเมินประสิทธิภาพของโมเดลในการตรวจจับคำไม่เป็นทางการในเอกสารจากปฏิบัติการทดลองโดยใช้ Confusion Matrix และ Classification Report

1.6. จัดทำเอกสารรายงานและการนำเสนอ

จัดทำรูปเล่มเอกสารรายงานและสไลด์สำหรับการนำเสนอ

3. เครื่องมือที่ใช้ในการดำเนินงาน

ในการจัดโครงการวิจัย เรื่อง ระบบตรวจจับข้อความไม่เป็นทางการในเอกสาร (Informal Text Detection System) ผู้จัดทำได้เลือกใช้เครื่องมือในการทำโครงการดังนี้

- 1.1. ใช้ Google Sheet สำหรับจัดเก็บข้อมูลข้อความไม่เป็นทางการในเอกสาร
- 1.2. ใช้ Google Colab สำหรับการเขียนและรันโค้ดภาษาไพธอนบนเว็บเบราว์เซอร์
- 1.3. ใช้ไลบรารี Pandas สำหรับแปลงข้อมูลให้อยู่ในรูปแบบ Data Frame เพื่อการจัดการและวิเคราะห์ข้อมูล
- 1.4. ใช้ไลบรารี Matplotlib สำหรับนำเสนอข้อมูลในรูปแบบแผนภูมิ
- 1.5. ใช้ไลบรารี PyThaiNLP สำหรับงานที่เกี่ยวข้องกับภาษาธรรมชาติที่เป็นภาษาไทย เช่น การตัดคำ
- 1.6. ใช้ไลบรารี Simple Transformers สำหรับการนำเข้าโมเดลที่ถูกฝึกก่อนหน้านี้ เช่น WangchanBERTa เพื่อที่จะนำมาฝึกต่อด้วยชุดข้อมูลข้อความไม่เป็นทางการในเอกสารและวัดประสิทธิภาพของโมเดล

บทที่ 4

ผลการดำเนินงาน

ในการจัดโครงการวิจัย เรื่อง ระบบตรวจจับข้อความไม่เป็นทางการในเอกสาร (Informal Text Detection System) ผู้จัดทำโครงการมีขั้นตอนในการดำเนินงาน ซึ่งจะทำให้ทราบถึงการวิเคราะห์โดยขั้นตอนในการดำเนินงานมีรายละเอียดดังนี้

1. การเก็บรวบรวมและเตรียมข้อมูลที่ใช้ในการศึกษา

[24] data_informal				
	title	topic	informal	formal
0	เว็บไซต์สำหรับโครงการทางวิทยาการคอมพิวเตอร์...	หลักการและเหตุผล	การเก็บข้อมูลโครงการของนักศึกษา เพื่อการเก็บ...	การเก็บข้อมูลโครงการของนักศึกษา เพื่อการเก็บ...
1	เว็บไซต์สำหรับโครงการทางวิทยาการคอมพิวเตอร์...	หลักการและเหตุผล	การเก็บข้อมูลโครงการของคณะวิทยาการคอมพิวเตอร์ ...	การเก็บข้อมูลโครงการของคณะวิทยาการคอมพิวเตอร์ ...
2	เว็บไซต์สำหรับโครงการทางวิทยาการคอมพิวเตอร์...	หลักการและเหตุผล	ดังนั้นการจัดทำโครงการจึงมีเป้าหมายเพื่อพัฒนา...	ดังนั้นการจัดทำโครงการจึงมีเป้าหมายเพื่อพัฒนา...
3	เว็บไซต์สำหรับโครงการทางวิทยาการคอมพิวเตอร์...	วัตถุประสงค์ของโครงการ	เพื่อพัฒนาเว็บไซต์สำหรับเก็บรวบรวมโครงการทาง...	เพื่อพัฒนาเว็บไซต์สำหรับเก็บรวบรวมโครงการทาง...
4	เว็บไซต์สำหรับโครงการทางวิทยาการคอมพิวเตอร์...	ทฤษฎีและผลงานวิจัยที่เกี่ยวข้อง	Framework คือ ชุดคำสั่ง เครื่องมือ หรือโครงสร้าง...	Framework คือ ชุดคำสั่ง เครื่องมือ หรือโครงสร้าง...
...	...	...	...	...
95	สแกนตรวจโรคเบาหวานขึ้นจอประสาทตาด้วย AI	ทฤษฎีและผลงานวิจัยที่เกี่ยวข้อง	Shah, P, Mishra, D. K., Shanmugam, M. P, Dos...	Shah, P, Mishra, D. K., Shanmugam, M. P, Dos...
96	สแกนตรวจโรคเบาหวานขึ้นจอประสาทตาด้วย AI	ทฤษฎีและผลงานวิจัยที่เกี่ยวข้อง	Sculley, D., Holt, G., Golovin, D., Davydov, E...	Sculley, D., Holt, G., Golovin, D., Davydov, E...
97	สแกนตรวจโรคเบาหวานขึ้นจอประสาทตาด้วย AI	ประโยชน์ที่คาดว่าจะได้รับ	โมเดลสามารถทำนายโรคเบาหวานขึ้นจอประสาทตา<infoc...	โมเดลสามารถทำนายโรคเบาหวานขึ้นจอประสาทตา<forma...
98	สแกนตรวจโรคเบาหวานขึ้นจอประสาทตาด้วย AI	ประโยชน์ที่คาดว่าจะได้รับ	ช่วยลดค่าใช้จ่ายที่เกิดจากการตรวจโรคด้วยแพทย์...	ช่วยลดค่าใช้จ่ายที่เกิดจากการตรวจโรคด้วยแพทย์...
99	สแกนตรวจโรคเบาหวานขึ้นจอประสาทตาด้วย AI	ประโยชน์ที่คาดว่าจะได้รับ	สถานพยาบาลและคลินิกที่มีทรัพยากรจำกัดหรือไม่...	สถานพยาบาลและคลินิกที่มีทรัพยากรจำกัดหรือไม่...

100 rows x 4 columns

ภาพที่ 6 ตัวอย่างชุดข้อมูลคำไม่เป็นทางการในเอกสารจาก Google Sheet

1.1. จากภาพที่ 2 แสดงข้อมูลคำไม่เป็นทางการในเอกสารจากซึ่งมีจำนวนทั้งหมด 4 คอลัมน์ได้แก่ title, topic, informal และ formal โดยผู้วิจัยได้เลือกให้คอลัมน์ informal สำหรับมาใช้ในการฝึกโมเดลซึ่งมีจำนวนประโยคทั้งหมด 100 ประโยคที่มีแท็ก informal เพื่อใช้ระบุคำไม่เป็นทางการ


[29] data_vulgar

	vulgar
0	ว่าใจ<vulgar>ไอ้ลั๊</vulgar>
1	ใจ<vulgar>ไอ้เหี้ย</vulgar>
2	ลั๊<vulgar>เหี้ย</vulgar>ไรขึ้นหลังหู เสียชาติ...
3	อะ ป่วยก็ป่วย งานจ้างก็ต้องทำ งานเรียนก็ต้องท...
4	โวย <vulgar>อีควาย</vulgar>หนักกว่า <vulgar>...
...	...
495	คิดถึงตอนเรียนง่วงเว้ย ตอนนั้นดี<vulgar>ฉิบหาย<...
496	การรู้มากเป็นความฉิบหายของชีวิตที่ต้องอยาก<vul...
497	ขอบคุณที่ให้สื่อช่องทางให้ติดต่อกับคุณ<vulgar>...
498	เกลียดการเกาหลังละแขนไม่ถึง<vulgar>ฉิบหาย</vu...
499	หล่อแต่<vulgar>ปากหมา</vulgar>ก็ไม่มีใครเอาท...

500 rows × 1 columns

ภาพที่ 7 ตัวอย่างชุดข้อมูลไม่สุภาพจาก Google Sheet


1.2. จากภาพที่ 3 แสดงข้อมูลคำไม่สุภาพในคอลัมน์ vulgar ซึ่งมีจำนวนประโยคทั้งหมด 500 ประโยคที่มีแท็ก vulgar เพื่อใช้ระบุคำไม่สุภาพ



ภาพที่ 8 แผนภูมิแท่งแสดงจำนวนความถี่ของประเภทของคำระหว่าง O และ INF

1.3. จากภาพที่ 4 แสดงถึงจำนวนความถี่ของประเภทของคำระหว่าง O และ INF โดย O มีจำนวน 18,206 และ INF มีจำนวน 2,297 ซึ่งแสดงให้เห็นถึงจำนวนของคำที่เป็นประเภท INF ซึ่งมีจำนวนที่น้อย

2. การทดสอบผลการดำเนินงาน



ภาพที่ 9 ผลการวัดประสิทธิภาพของโมเดลจากชุดข้อมูลทดสอบ

3.1. จากภาพที่ 5 แสดงประสิทธิภาพจากการทำนายของโมเดลด้วยชุดข้อมูลการทดสอบซึ่งได้ค่า Precision เท่ากับ 71.62% ค่า Recall เท่ากับ 70.31% และค่า F1-Score เท่ากับ 70.96%

บทที่ 5

บทสรุป

1. สรุปผลการดำเนินโครงการ

การทำโครงการวิจัยนี้ได้พัฒนาโมเดลสำหรับตรวจจับข้อความไม่เป็นทางการในเอกสารด้วยการนำโมเดลภาษาไทยคือ WangchanBERTa ไปฝึกเพิ่มเติมด้วยชุดข้อมูลเอกสารวิจัยจากรายวิชาสัมมนาทางวิทยาการคอมพิวเตอร์จำนวน 100 ประโยคและประโยคจากข้อความคำไม่สุภาพจำนวน 500 ประโยค ผลจากการวัดประสิทธิภาพของโมเดลด้วย F1-Score สรุปได้ว่าโมเดลมีความแม่นยำ 70.96% จากการวินิจฉัยของทางผู้วิจัยคาดว่าสาเหตุมาจากจำนวนชุดข้อมูลคำไม่เป็นทางการจากเอกสารมีจำนวนไม่มากพอและการระบุคำไม่เป็นทางการในชุดข้อมูลควรถูกระบุโดยผู้เชี่ยวชาญ

2. ปัญหาอุปสรรค และ แนวทางแก้ไข

- 1.1. จำนวนชุดข้อมูลคำไม่เป็นทางการจากเอกสารมีจำนวนไม่มากพอ ส่งผลให้โมเดลมีความแม่นยำในการทำนายที่น้อย
- 1.2. การระบุคำไม่เป็นทางการในชุดข้อมูลคำไม่เป็นทางการจากเอกสารควรถูกระบุโดยผู้เชี่ยวชาญ
- 1.3. ในกระบวนการเตรียมข้อมูลจำเป็นต้องมีการตัดคำและระบุประเภทของคำ ทางผู้วิจัยได้ใช้การตัดคำภาษาไทยด้วยไลบรารี PyThaiNLP ซึ่งมีความถูกต้องในการตัดคำไม่มากพอ ส่งผลให้โมเดลทำนายประเภทของคำมีความไม่ถูกต้อง

3. ข้อเสนอแนะ ในการพัฒนาต่อไป

- 1.1. จากการวินิจฉัยเบื้องต้นคาดว่าประสิทธิภาพของโมเดลจะดียิ่งขึ้นหากมีจำนวนของข้อมูลในชุดข้อมูลข้อความไม่เป็นทางการในเอกสารมีจำนวนมากขึ้นและการระบุคำที่ไม่เป็นทางการในชุดข้อมูลควรถูกระบุโดยผู้เชี่ยวชาญ
- 1.2. โมเดลนี้จะมีประโยชน์มากขึ้นหากสามารถแปลงข้อความที่ไม่เป็นทางการให้อยู่ในรูปแบบของข้อความที่เป็นทางการ

บรรณานุกรม

- Al-Ghamdi, S. A., Khabti, J., & Al-Khalifa, H. S. (2017). **Exploring NLP web APIs for building Arabic systems**. 2017 12th International Conference on Digital Information Management, ICDIM 2017, 2018-January, 175–178. <https://doi.org/10.1109/ICDIM.2017.8244649>
- Hasan, S. Al, Hussain, M. G., Protim, J., Rahman, M. M., Fahim, N., Chowdhury, M. Z., & Pritom, A. I. (2022). **Classification of Multi-Labeled Text Articles with Reuters Dataset using SVM**. 2022 International Conference on Science and Technology, ICOSTECH 2022. <https://doi.org/10.1109/ICOSTECH54296.2022.9829153>
- Jia, L., Jiang, T., Meng, J. H., & Zhang, T. (2020). Tibetan text classification method based on BiLSTM model. Proceedings - International Conference on Artificial Intelligence and Electromechanical Automation, AIEA 2020, 27–31. <https://doi.org/10.1109/AIEA51086.2020.00013>
- Li, X., Qian, Y., & Dou, L. (2021). **BERT Named Entity Recognition with Self-Attention Mechanism**. 2021 IEEE Conference on Telecommunications, Optics and Computer Science, TOCS 2021, 119–123. <https://doi.org/10.1109/TOCS53301.2021.9688590>
- Sasiwut Chaiyadecha. (2021). **Language Model WangchanBERTa และ WangChanGLM คืออะไร**. Retrieved January 7, 2024, from <https://lengyi.medium.com/word-embedding-word2vec-nlp-model-dbc4c892dfb9>
- Yadav, R., & Bhat, A. (2022). **Applications of Deep Learning for Disease Management**. Proceedings - 2022 4th International Conference on Advances in Computing, Communication Control and Networking, ICAC3N 2022, 1058–1063. <https://doi.org/10.1109/ICAC3N56670.2022.10074269>
- Yu, B., Deng, C., & Bu, L. (2022). **Policy Text Classification Algorithm Based on Bert**. Proceedings - 2022 11th International Conference of Information and Communication Technology, ICTech 2022, 488–491. <https://doi.org/10.1109/ICTECH55460.2022.00103>
- Zhang, B. (2022). **News Text Classification Algorithm Based on Machine Learning Technology**. Proceedings - 2022 International Conference on Education, Network and Information Technology, ICENIT 2022, 182–186. <https://doi.org/10.1109/ICENIT57306.2022.00047>
- Tadej Magajna. (2022). **Natural Language Processing with Flair: A practical guide to understanding and solving NLP problems with Flair**. Retrieved January 7, 2024, from <https://learning.oreilly.com/library/view/natural-language-processing/9781801072311>
- ทีมงานทรูปลูกปัญญา. (2564). **ระดับภาษา**. สืบค้นเมื่อ 7 มกราคม 2567, จาก <https://www.truelookpanya.com/learning/detail/34242>

- กานดา รุณนะพงศา และ ปโยธ อูราธรรมกุล. (2548). การตัดคำภาษาไทยโดยการปรับปรุงกฎและพจนานุกรมแบบใหม่. สืบค้นเมื่อ 7 มกราคม 2567, จาก <https://gear.kku.ac.th/~krunapon/research/thaiWordsSegmentation/FinalReportThaiWordsSegmentation.pdf>
- วิกิพีเดีย. (). . สืบค้นเมื่อ 7 มกราคม 2567, จาก <https://th.wikipedia.org/wiki/โครงข่ายประสาทเทียม>
- สรณสรณ์. (2010). ลักษณะ การใช้และความหมายของภาษาสแลงในนิตยสารวัยรุ่น. สาขาวิชาภาษาและการสื่อสารระหว่างวัฒนธรรม มหาวิทยาลัยศิลปากร http://www.thapra.lib.su.ac.th/objects/thesis/fulltext/thapra/Satanasorn_Yutibun/Fulltext.pdf
- อภิชาติ บุญรอด. (2023). Language Model WangchanBERTa และ WangChanGLM คืออะไร. สืบค้นเมื่อ 7 มกราคม 2567, จาก <https://visai.ai/th/blogs/12/language-model-wangchanberta-wangchanglm>

ประวัติผู้เขียน

นายณัฐนันท์ ทองชุมภู เกิดเมื่อวันที่ 17 กุมภาพันธ์ พ.ศ. 2546 กำลังศึกษาระดับปริญญาตรีวิทยาศาสตร์บัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ จากวิทยาลัยการคอมพิวเตอร์มหาวิทยาลัยขอนแก่น เมื่อปีการศึกษา 2564

นายกิตติภพ เพ็ชรปรี เกิดเมื่อวันที่ 16 พฤษภาคม พ.ศ. 2544 กำลังศึกษาระดับปริญญาตรีวิทยาศาสตร์บัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ จากวิทยาลัยการคอมพิวเตอร์มหาวิทยาลัยขอนแก่น เมื่อปีการศึกษา 2564

ลงชื่อผู้จัดทำ.....
(นายณัฐนันท์ ทองชุมภู)

ลงชื่อผู้จัดทำ.....
(นายกิตติภพ เพ็ชรปรี)
วันที่/...../.....

การตรวจสอบจากอาจารย์ที่ปรึกษาโครงงาน

.....
.....
.....

(ลงชื่อ).....
(อ.ดร.พงษ์ศธร จันทรรยอย)
วันที่/...../.....